

平成 31 年度

卒業論文

複雑環境下でのロボット学習に向けた
深層状態空間モデルを用いた映像予測

平成 32 年 2 月

指導教員 松尾豊教授

東京大学工学部システム創成学科

知能社会システムコース

03-180961 近藤生也

概要

近年、深層ニューラルネットワーク (DNN) を使用した機械学習手法の発展を背景としてロボットの制御方策を自ら学習させるロボット学習の研究が進んでいる。ロボット学習において未来の観測、特に自らの行動に対するフィードバックを適切に予測するよう学習することは、環境の遷移モデル (内部モデル) を獲得すること、そしてそれを用いたプランニングや行動結果の予測、安全性の評価などに欠かせない。時間変化する環境の DNN を用いたモデルとして深層状態空間モデル (Deep State Space Model) があり、これは昨今深層強化学習の分野で取り入れられているが、深層状態空間モデルを用いて映像予測を学習することで内部モデルが獲得できるとされている [1]。しかし現在一般的に使われて深層状態空間モデルとその学習方法は各時刻の状態が低次元のベクトルで表現できるという仮定を暗に置いており、高次元な表現を仮定すると学習が進まず、複雑な環境の予測問題にスケールさせる方法は自明でない。

本研究ではまずこのような問題があることを実験的に指摘した上で、状態の表現に階層性を考えることで深層状態空間モデルにより高次元な状態表現を仮定できるように拡張し、低次元な表現を仮定した場合よりも良い表現が獲得できることを示す。評価実験では様々な物体が置かれた机上でのマニピュレーションを題材にしたデータセットを用いてロボットの行動で条件付けた映像予測を行う。単純な深層状態空間モデルをベースラインに設定し、提案手法の定性的・定量的な有効性を示す。

目次

| | |
|--------------------------------------|---|
| 概要 | i |
| 第 1 章 状態表現の階層性を考慮することによる深層状態空間モデルの拡張 | 1 |
| 1.1 問題設定 | 1 |
| 1.2 ベースライン | 1 |
| 1.3 提案手法 | 1 |
| 1.3.1 状態表現の階層性 | 2 |
| 1.3.2 階層的な状態表現の遷移 | 3 |
| 1.3.3 確率モデル・最適化 | 3 |
| 1.3.4 データの生成方法 (評価時) | 4 |
| 1.4 類似手法との差分 | 4 |
| 第 2 章 実験 | 5 |
| 2.1 実験内容 | 5 |
| 2.1.1 実験概要 | 5 |
| 2.1.2 BAIR Push Dataset | 5 |
| 2.1.3 hogehoge スコア | 5 |
| 2.1.4 実験条件 | 6 |
| 2.1.5 学習時のテクニック | 6 |
| 2.2 実験結果 | 6 |
| 2.2.1 定量評価 (尤度) | 6 |
| 2.2.2 定量評価 (hogehoge スコア) | 6 |
| 2.2.3 定性評価 | 6 |
| 第 3 章 考察 | 7 |

| | | |
|-------|-------------------------|----|
| 3.1 | 本研究の貢献 | 7 |
| 3.2 | 今後の課題 | 7 |
| 3.2.1 | 転移学習 | 7 |
| 3.3 | 社会応用 | 7 |
| 3.3.1 | 実機ロボット | 7 |
| 3.3.2 | 物理シミュレーションの近似 | 7 |
| 第 4 章 | まとめ | 9 |
| | 謝辞 | 10 |
| | 参考文献 | 11 |

目次

| | | |
|-----|--|---|
| 1.1 | hierarchical | 2 |
| 1.2 | transition base | 3 |
| 1.3 | transition proposal | 3 |
| 1.4 | proposal 2 つずつ記載されている ot は同じデータを示すが、異なる s から独立に生成されることを明示している. | 4 |

表目次

第 1 章

状態表現の階層性を考慮することによる深層状態空間モデルの拡張

を目指す。

はじめに、提案手法で扱う問題設定について整理し、その後提案手法の具体的な説明として、確率モデル・最適化とモデルアーキテクチャについて述べていく。

1.1 問題設定

本研究では行動条件付き映像予測の問題を解く。具体的には、ある行動主体が実行した行動系列 \vec{a} とその結果観測される観測系列 \vec{o} のセット $\{\vec{a}, \vec{o}\}$ が予め多数与えられたときに、未知の初期状態と行動系列から結果として観測される映像を予測できるようにする。

1.2 ベースライン

本研究では 2 章で述べたシンプルな DSSM をベースラインにおく。

1.3 提案手法

3 章で述べたように、ベースラインは潜在変数の次元を大きくすると学習がうまく行かない。提案手法は、より豊かな状態表現を獲得できるようにするようベースラインの DSSM を拡張することが目的である。

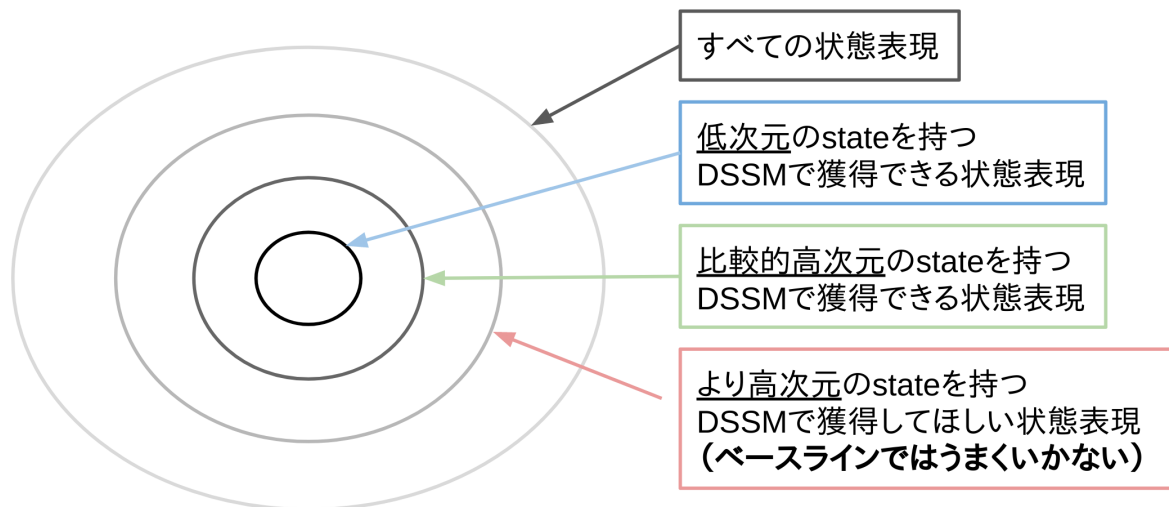


Fig. 1.1 hierarchical

1.3.1 状態表現の階層性

まず、潜在変数の次元を変えた時に獲得される情報について考察する。状態表現学習によって、ベースラインモデルが潜在変数の次元を変えたときに獲得する情報と、潜在変数を高次元にした際に獲得してほしい情報、そしてすべての情報の関係性を考える。

中心的な情報から順に獲得される。中心的な情報が獲得できないうちに表面的な情報を獲得しても、中心的な表現が間違っていれば生成されるものも異なり、学習時に誤差を小さくできないからである。というように、現実的なデータの背後にある状態表現には階層性がある。今、低次元であればまず背景、次によく動く部分、最後に細かいテクスチャ、という順番に学習されるのが合理的である。つまり、state の次元を大きくしたときに学習される情報には図のような包含関係がある。

今、

理想的には、state の次元を徐々に大きくすることである。ベースラインでは、Fig 1.1 の赤で示した部分をいきなり学習しようとするが、

ただし状態表現の外側になるほど得られるデータが疎になるので、表現としては獲得しにくくなるモデルに正規分布を仮定していることによる表現力の制約などを除けば、




Fig. 1.2 transition base




Fig. 1.3 transition proposal

1.3.2 階層的な状態表現の遷移

前節より、状態表現に階層性があることを述べたが、この節では階層的な状態表現の遷移を考える。遷移にも順序がある。つまり、中心的な状態表現が遷移した後、更新前を白で、更新後を灰色で表しているベースラインの DSSM モデルは、提案する HDSSM の特別な場合と解釈することもできる。

1.3.3 確率モデル・最適化

ここまでで、潜在変数の次元を大きくした際に、獲得できる状態表現とその遷移がどのようなものかを考察した。考慮すべき点は以下のようになる。

- 1 state に大きな次元を仮定した際、state の推論が難しいため学習が難しく不安定になる。
- 2 状態表現には階層性があり、表面的な状態表現になるほど学習が難しくなるが、中心的な状態表現はベースライン手法で学習ができる。
- 3 状態表現の遷移には順序があり、大きな潜在表現の遷移を直接学習するのは難しいが、中心的な潜在表現の遷移を学習することはベースライン手法でも可能である。

これらを踏まえて、次を満たすモデルを考えることにした。1. a

最終的に Fig. 1.4 のようなモデルを提案する。

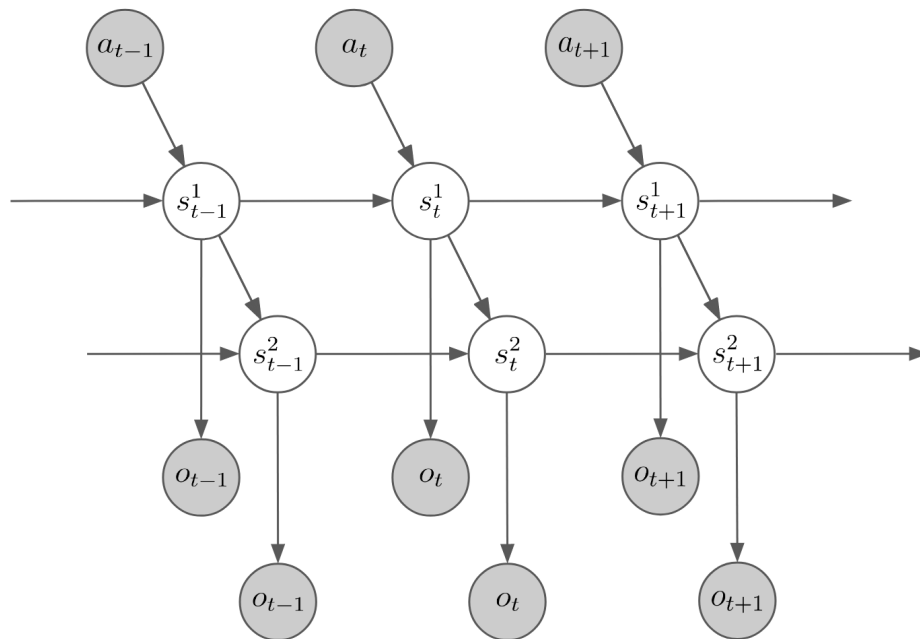


Fig. 1.4 proposal 2 つずつ記載されている o_t は同じデータを示すが、異なる s から独立に生成されることを明示している。

1.3.4 データの生成方法 (評価時)

1.4 類似手法との差分

DRAW^[1] は VAE の潜在変数に階層性をもたせたモデルで、データに遷移はないが、狙いは提案手法と似ている。多層 RNN^[2] は直前の観測を逐次的に入力す planet で RNN ベースはダイナミクスの獲得が弱く、長期の予測が難しいと報告されている。FHMM は離散低次元で EM アルゴリズムによって最適化をしている

第 2 章

実験

本研究では，第 1 章で述べた提案手法の有効性を検証するために， で使用されている Shepard Metzler データセットを用いて，評価実験を行った．本章では，行なった実験の内容について説明した後，実験結果について述べていく．最後に実験結果を踏まえた考察を行う．

2.1 実験内容

潜在変数の次元は、5 章で示すように学習がある程度進むことが確認できた〇〇 64 次元 〇〇次元をベースラインとして設定する．

2.1.1 実験概要

adam 評価指標には，予測誤差 (負の対数尤度)，hogehoge スコアを用いる push dataset を使う

2.1.2 BAIR Push Dataset

2.1.3 hogehoge スコア

オリジナル/ノンオリジナル

2.1.4 実験条件

2.1.5 学習時のテクニック

2.2 実験結果

2.2.1 定量評価 (尤度)

安定した.

潜在変数のサンプリングが安定し, KL 項が安定して下がりやすくなったからだと思ふ
尤度が下がった

2.2.2 定量評価 (hoge hoge スコア)

2.2.3 定性評価

きれいになってくれ

第 3 章

考察

3.1 本研究の貢献

3.2 今後の課題

3.2.1 転移学習

環境のダイナミクスとして、普遍的な物理法則を一部獲得していると考えられることから、様々なタスクで特に階層的なモデルでは、低次元の state に大域的な物理法則に関するダイナミクス、高次元の state に比較的表面的なダイナミクスを獲得していると考えられ、普遍的な環境の多少の変化には

3.3 社会応用

3.3.1 実機ロボット

非剛体物体のマニピュレーションが考えられる。

3.3.2 物理シミュレーションの近似

本研究で扱った深層学習ベースの行動条件付き映像予測では物理現象の結果として観測されるデータの近似を行うが、これは物理現象の近似という意味で現行の物理シミュレーションソフトウェアと同じことを行っていると解釈ができる。現在、物理シミュレーションの手法としては、既知の様々なスケールの物理法則を記述し微小時間・微小空間単位で逐次的に各領域の状態を計算し全体の結果を予測することが一般的である。しかしこのアプローチは、物理法則が既知である必要があり、また複雑な物理法則に対しては予測に膨大な時間がかかりリアルタ

イムに予測ができないという問題がある。例えば [] は、蕎麦にオイスターソースをかけて混ぜる物理シミュレーションを扱っているが、1 フレームごとの見た目はとてもリアルなものの物理現象としては以前不自然な部分があり、さらに 30fps で 1 秒の予測をするのに 29 時間かかると報告している。現行の物理演算ベースの映像予測に対し深層学習ベースの映像予測は、物理法則の正しさや多視点から見た際の一貫性が保証できないなど機能として制限は多いものの、必ずしも物理現象が既知である必要はなく、また一度学習すればリアルタイムで予測を行うことができる。さらに、必要なデータを集めることで機能の制限を解消することもできるはずである。

これからの人工知能の研究には仮想現実環境の開発が欠かせない。このことは、昨今強化学習やロボット学習の分野で相次いで世界中の研究機関が学習用のシミュレーション環境 [Meta world, control suit, RLBench] を開発し公開していることから伺える。物理的なタスクを解けるよう学習するには実環境では危険であったり学習の並列化が難しいため、先にシミュレーション内で学習することが有効である [sim2real の論文]。また、与えられたタスクやタスクの集合を解くようトップダウン型の人工知能研究とは対比的に、動物の知能の仕組みや知性の獲得の過程を再現するボトムアップ型の人工知能研究も大切であり [考える脳]、ボトムアップ型人工知能研究にも仮想現実環境が必要であると考えられる (The Two Faces of Tomorrow, SAO)

これらの人工知能研究の動向・方向性を踏まえ、物理演算ベースと深層学習ベースの物理シミュレーションの融合、あるいは深層学習ベースによる代替を模索することも重要になるだろう。

第 4 章

まとめ

本論文では、はじめに について取り上げ、その問題点として である点を挙げた。そして、その問題点の原因として、 を指摘し、 を行なった。

そこで、本論文では、これらの問題点を解消する改善手法の提案を行なった。提案手法では、 することで、 し、 を可能にした。

実験では、BAIR Push Dataset を用いてベースライン手法を比較し、定性的・定量的な評価を行なった。提案手法は、 においてベースライン手法である を上回る結果となり、提案手法が が実験的にも示された。

最後に考察として、今後の課題や社会応用について議論し、本研究が深層生成モデルを用いて観測情報から環境をモデル化する世界モデルの研究の 1 つとして位置付けられることを述べ、今後の研究の方向性についての展望を整理した。

本研究は、既存の工学的な技術の代替としてのみならず、より汎用的な人工知能技術の達成のために重要な技術の 1 つであると考えており、今後も実環境への提案手法の適用や、時系列遷移を考慮したモデルの考案、強化学習技術との融合などを見据えて、人工知能分野の研究の発展に貢献していきたいと考えている。

謝辞

本論文を作成するにあたり，多くの方々にご協力をいただきました．

最後に，配属からの一年間，あらゆる面でサポートをしてくださった松尾研究室の皆様に御礼申しあげて，謝辞とさせていただきます．

東京大学工学工学部システム創成学科

知能社会システムコース

松尾研究室学部 4 年

平成 31 年 2 月 近藤生也

参考文献

- [1] Karol Gregor, Ivo Danihelka, Alex Graves, Danilo Jimenez Rezende, and Daan Wierstra. Draw: A recurrent neural network for image generation. *arXiv preprint arXiv:1502.04623*, 2015.